

17-20 sept 2013

CAEPIA'13

Madrid



Big Data

Francisco Herrera

**Research Group on Soft Computing and
Information Intelligent Systems (SCI²S)
Dept. of Computer Science and A.I.
University of Granada, Spain**

Email: herrera@decsai.ugr.es
<http://sci2s.ugr.es>

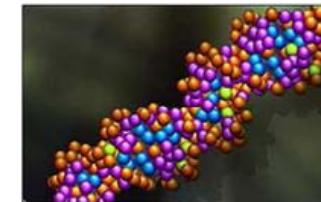


DECSAI
Universidad de Granada

Big Data

Nuestro mundo gira en torno a los datos

- Ciencia
 - Bases de datos de astronomía, genómica, datos medio-ambientales, datos de transporte, ...



- Ciencias Sociales y Humanidades
 - Libros escaneados, documentos históricos, datos sociales, ...



- Negocio y Comercio
 - Ventas de corporaciones, transacciones de mercados, censos, tráfico de aerolíneas, ...



- Entretenimiento y Ocio
 - Imágenes en internet, películas, ficheros MP3, ...

- Medicina
 - Datos de pacientes, datos de escaner, radiografías ...



- Industria, Energía, ...
 - Sensores, ...

Big Data



Alex ' Sandy' Pentland, director del programa de emprendedores del 'Media Lab' del Massachusetts Institute of Technology (MIT)

INTERNET | Campus Party Europa 2013

'Es la década de los datos y de ahí vendrá la revolución'



**Considerado por
'Forbes' como uno
de los siete
científicos de
datos más
poderosos del
mundo**

data

mobile time Data
Twitter databases terabytes
NoSQL SQL Hadoop support
big-data new storage
example column-store processing information
analyses compression query big database

Outline

- ¿Qué es Big Data?
- MapReduce: Paradigma de Programación para Big Data (Google)
- Plataforma Hadoop (Open access)
- Librería Mahout para Big Data. Otras librerías
- Limitaciones de MapReduce
- Comentarios Finales



Outline

- **¿Qué es Big Data?**
- MapReduce: Paradigma de Programación para Big Data (Google)
- Plataforma Hadoop (Open access)
- Librería Mahout para Big Data. Otras librerías
- Limitaciones de MapReduce
- Comentarios Finales



¿Qué es Big Data?


No hay una definición estándar



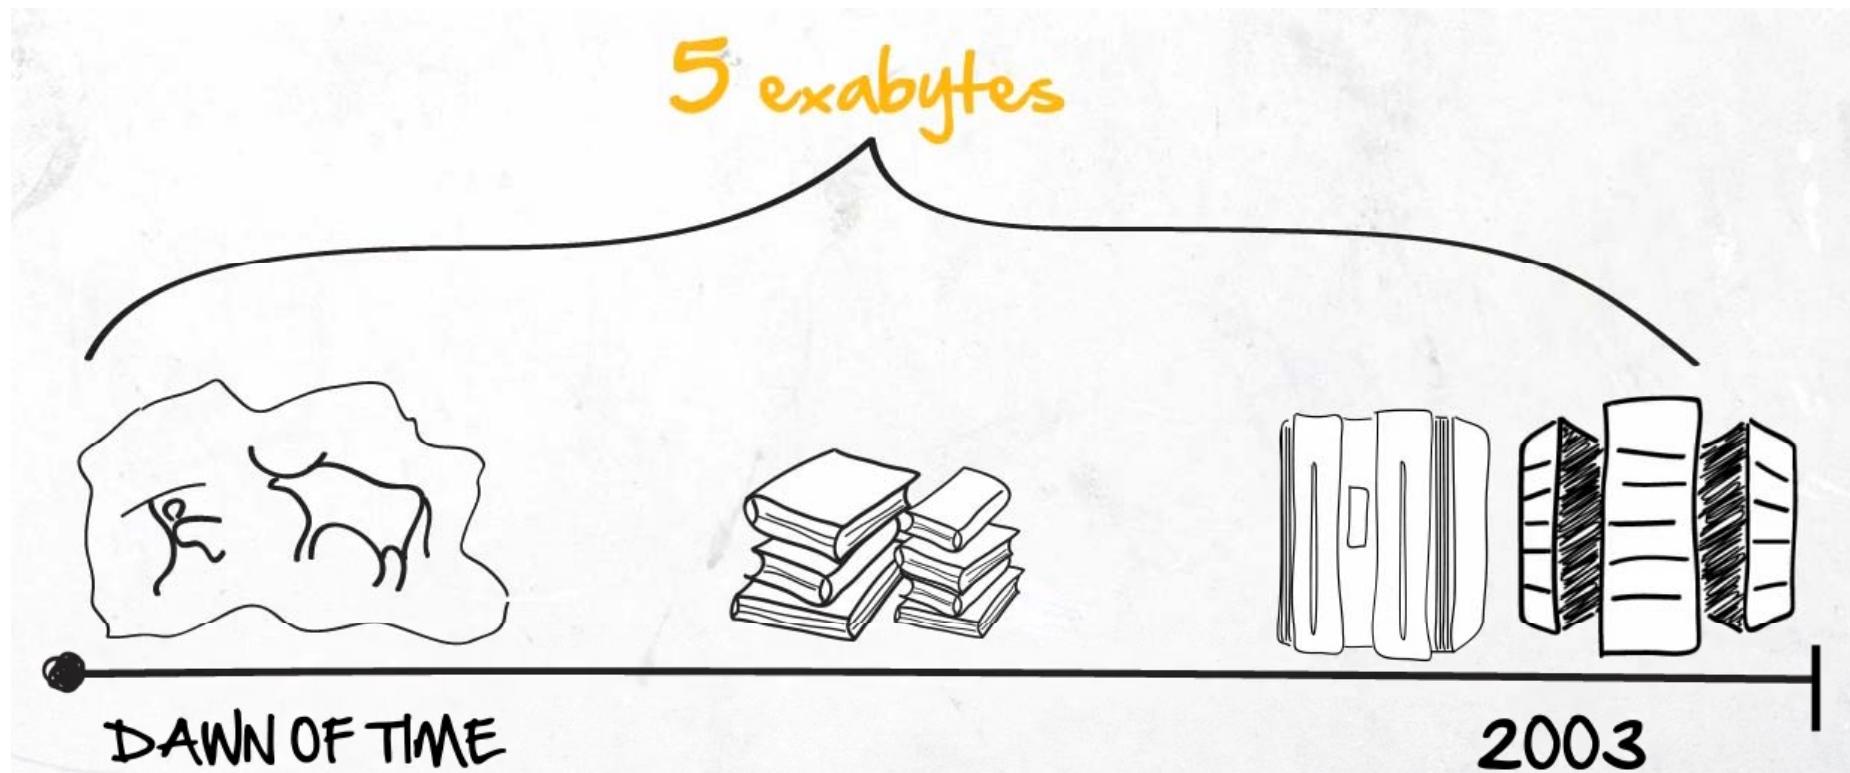
Big data es una colección de datos grande, complejos, **muy difícil de procesar a través de herramientas de gestión y procesamiento de datos tradicionales**




"**Big Data**" son datos cuyo volumen, diversidad y complejidad **requieren nueva arquitectura, técnicas, algoritmos y análisis** para gestionar y extraer valor y conocimiento oculto en ellos ...



¿Qué es Big Data?



¿Qué es Big Data?



¿Qué es Big Data? 3 V's de Big Data






¿Qué es Big Data? 3 V's de Big Data

1^a:Volumen


El volumen de datos crece exponencialmente

- Crecimiento x 44 de 2009 a 2020
- De 0.8 zettabytes a 35ZB



Crecimiento exponencial en los datos generados/almacenados

¿Qué es Big Data? 3 V's de Big Data



¿Qué es Big Data? 3 V's de Big Data

2^a:Velocidad


- Los DATOS se generan muy rápido y necesitan ser procesados rápidamente
- Online Data Analytics
- Decisiones tardías → oportunidades perdidas



Ejemplos:

- **E-Promociones:** Basadas en la posición actual e historial de compra → envío de promociones en el momento de comercios cercanos a la posición
- **Monitorización/vigilancia sanitaria:** Monitorización sensorial de las actividades del cuerpo → cualquier medida anormal requiere una reacción inmediata





¿Qué es Big Data? 3 V's de Big Data



¿Qué es Big Data? 3 V's de Big Data

3^a:Variedad


- Varios formatos y estructuras:
Texto, numéricos, imágenes, audio,
video, secuencias, series temporales
...
- Una sola aplicación puede generar
muchos tipos de datos



Extracción de conocimiento →
Todos estos tipos de datos
necesitan ser analizados
conjuntamente







¿Qué es Big Data? 3 V's de Big Data



¿5V's?

¿Qué es Big Data? 3 V's de Big Data

4^aV
↓
Veracidad

Volume	Velocity	Variety	Veracity*
			
Data at Rest Terabytes to exabytes of existing data to process	Data in Motion Streaming data, milliseconds to seconds to respond	Data in Many Forms Structured, unstructured, text, multimedia	Data in Doubt Uncertainty due to data inconsistency & incompleteness, ambiguities, latency, deception, model approximations

¿Qué es Big Data?



Datos no estructurados

¿Qué es Big Data?


Aproximaciones
y tecnologías
innovativas



MapReduce



APACHE
GIRAPH



¿Qué es Big Data?

¿Quién genera Big Data?




Redes sociales y multimedia
(todos generamos datos)



Instrumentos científicos
(colección de toda clase de datos)



Dispositivos móviles
(seguimiento de objetos)



Redes de sensores
(se miden toda clase de datos)

El progreso y la innovación ya no se ven obstaculizados por la capacidad de recopilar datos, sino por la capacidad de gestionar, analizar, sintetizar, visualizar, y descubrir el conocimiento de los datos recopilados de manera oportuna y en una forma escalable


Big Data. Aplicaciones

Astronomía



- Astronomical sky surveys
- 120 Gigabytes/week
- 6.5 Terabytes/year

Genómica



- 25,000 genes in human genome
- 3 billion bases
- 3 Gigabytes of genetic data

Telefonía




- 250M calls/day
- 60G calls/year
- 40 bytes/call
- 2.5 Terabytes/year

Transacciones de tarjetas de crédito



- 47.5 billion transactions in 2005 worldwide
- 115 Terabytes of data transmitted to VisaNet data processing center in 2004

Tráfico en Internet



- Traffic in a typical router:
- 42 kB/second
 - 3.5 Gigabytes/day
 - 1.3 Terabytes/year

Procesamiento de información WEB



- 251
- 10k
- 250
- *De
- timi



Outline

- ¿Qué es Big Data?
- **MapReduce: Paradigma de Programación para Big Data (Google)**
- Plataforma Hadoop (Open access)
- Librería Mahout para Big Data. Otras librerías
- Limitaciones de MapReduce
- Comentarios Finales



MapReduce

- **Problema:** Escalabilidad de grandes cantidades de datos
- **Ejemplo:**
 - Exploración 100 TB en 1 nodo @ 50 MB/sec = 23 días
 - Exploración en un clúster de 1000 nodos = 33 minutos
- **Solución → Divide-Y-Vencerás**



Una sola máquina no puede gestionar grandes volúmenes de datos de manera eficiente



MapReduce

- Escalabilidad de grandes cantidades de datos
 - Exploración 100 TB en 1 nodo @ 50 MB/sec = 23 días
 - Exploración en un clúster de 1000 nodos = 33 minutos


Solución → Divide-Y-Vencerás

MapReduce

- Modelo de programación de datos paralela
- Concepto simple, elegante, extensible para múltiples aplicaciones
- **Creado por Google (2004)**
 - Procesa 20 PB de datos por día
- **Popularizado por el proyecto de código abierto Hadoop**
 - Usado por [Yahoo!](#), [Facebook](#), [Amazon](#), ...

MapReduce

Programming
Framework





MapReduce

Características

■ Paralelización automática:

- Dependiendo del tamaño de ENTRADA DE DATOS → se crean multiples tareas MAP
- Dependiendo del número de intermedio <clave, valor> particiones → se crean tareas REDUCE

■ Escalabilidad:

- Funciona sobre cualquier cluster de nodos/procesadores
- Puede trabajar desde 2 a 10,000 máquinas

■ Transparencia programación

- Manejo de los fallos de la máquina
- Gestión de comunicación entre máquina



MapReduce

Características

- **Tiempo de ejecución:**
 - Partición de datos
 - Programación de la tarea
 - Manejo de los fallos de la máquina
 - Gestión de comunicación entre máquina

MapReduce

El número de Maps
es independiente
del número de
nodos disponibles




VS





El número de Maps es independiente del número de nodos disponibles




Almacenamiento con copias, normalmente r=3



MapReduce

Completamente transparente para el programador





MapReduce

Resumiendo:

- **Ventaja frente a los modelos distribuidos clásicos:**
El modelo de programación paralela de datos de MapReduce oculta la complejidad de la distribución y tolerancia a fallos
- **Claves de su filosofía:** Es
 - **escalable:** se olvidan los problemas de hardware
 - **más barato:** se ahorran costes en hardware, programación y administración
- **MapReduce no es adecuado para todos los problemas, pero cuando funciona, puede ahorrar mucho tiempo**

Outline

- ¿Qué es Big Data?
- MapReduce: Paradigma de Programación para Big Data (Google)
- **Plataforma Hadoop (Open access)**
- Librería Mahout para Big Data. Otras librerías
- Limitaciones de MapReduce
- Comentarios Finales



Hadoop





Hadoop es una implementación de código abierto del paradigma computacional MapReduce



Hadoop



Hadoop Distributed File System (HDFS) es un sistema de archivos distribuido, escalable y portátil escrito en **Java** para el framework Hadoop



Creado por **Doug Cutting** (chairman of board of directors of the Apache Software Foundation, 2010)

<http://hadoop.apache.org/>



Hadoop



<http://sortbenchmark.org/>

Primer hito de Hadoop: July 2008 - Hadoop Wins Terabyte Sort Benchmark

Uno de los grupos de Yahoo Hadoop ordenó 1 terabyte de datos en 209 segundos, superando el récord anterior de 297 segundos en la competición anual de ordenación de un terabyte (Daytona).

Esta es la primera vez que un programa en Java de código abierto ganó la competición.

2008, 3.48 minutes

Hadoop

910 nodes x (4 dual-core processors, 4 disks, 8 GB memory)
Owen O'Malley, Yahoo

2007, 4.95 min

TokuSampleSort

tx2500 disk cluster
400 nodes x (2 processors, 6-disk RAID, 8 GB memory)
Bradley C. Kuszmaul , MIT

Daytona

2013, 1.42 TB/min

Hadoop

102.5 TB in 4,328 seconds
2100 nodes x
(2 2.3Ghz hexcore Xeon E5-2630, 64 GB memory, 12x3TB disks)
Thomas Graves
Yahoo! Inc.

<http://developer.yahoo.com/blogs/hadoop/hadoop-sorts-petabyte-16-25-hours-terabyte-62-422.html>

Hadoop



<http://hadoop.apache.org/>

¿Qué es Apache Hadoop?



Apache™ Hadoop® es un proyecto que desarrolla software de código abierto fiable, escalable, para computación distribuida

Hadoop se puede ejecutar de tres formas distintas (configuraciones):

- 1. Modo Local / Standalone.** Se ejecuta en una única JVM (*Java Virtual Machine*). *Esto es útil para depuración*
- 2. Modo Pseudo-distribuido** (simulando así un clúster o sistema distribuido de pequeña escala)
- 3. Distribuido (Clúster)**



Hadoop



¿Cómo accedo a una plataforma Hadoop?

Plataformas Cloud con instalación de Hadoop

Amazon Elastic Compute Cloud (Amazon EC2)

<http://aws.amazon.com/es/ec2/>



Windows Azure

<http://www.windowsazure.com/>

Instalación en un cluster privado

Ejemplo: Cluster ATLAS, 12 nodos (UGR)

- Microprocessors: 2 x Intel E5-2620 (6 cores/12 threads, 2 GHz)
- RAM 64 GB DDR3 ECC 1600MHz

¿Cómo puedo instalar Hadoop?

cloudera® Distribución que ofrece Cloudera para Hadoop.

Ask Bigger Questions

<http://www.cloudera.com/content/cloudera/en/why-cloudera/hadoop-and-big-data.html>

¿Qué es Cloudera? Cloudera es la primera distribución Apache Hadoop comercial y no-comercial.

Outline

- ¿Qué es Big Data?
- MapReduce: Paradigma de Programación para Big Data (Google)
- Plataforma Hadoop (Open access)
- **Librería Mahout para Big Data. Otras librerías**
- Limitaciones de MapReduce
- Comentarios Finales



Mahout



Scalable machine learning and data mining



Apache Mahout has implementations of a wide range of machine learning and data mining algorithms:
clustering, classification, collaborative filtering and frequent pattern mining



Mahout currently has

- Collaborative Filtering
- User and Item based recommenders
- K-Means, Fuzzy K-Means clustering
- Mean Shift clustering
- Dirichlet process clustering
- Latent Dirichlet Allocation
- Singular value decomposition

- Parallel Frequent Pattern mining
- Complementary Naive Bayes classifier
- Random forest decision tree based classifier
- High performance `java` collections (previously colt collections)
- A vibrant community
- and many more cool stuff to come by this summer thanks to Google summer of code



Biblioteca de código abierto en APACHE

<http://mahout.apache.org/>


Mahout



Scalable machine learning and data mining

Apache Mahout has implementations of a wide range of machine learning and data mining algorithms: clustering, classification, collaborative filtering and frequent pattern mining

Cuatro grandes áreas de aplicación




Clasificación

Agrupamiento

Asociación



Sistemas de Recomendaciones



Mahout



Scalable machine learning and data mining

Apache Mahout has implementations of a wide range of machine learning and data mining algorithms: clustering, classification, collaborative filtering and frequent pattern mining



Caso de estudio: Random Forest para KddCup99

Clase	Nº de instancias
normal	972.781
DOS	3.883.370
PRB	41.102
R2L	1.126
U2R	52

Tabla 2: Número de instancias por clase

Tiempo en segundos para ejecución secuencial

Datasets	RF		
	10%	50%	full
DOS_versus_normal	6344.42	49134.78	NC
DOS_versus_PRB	4825.48	28819.03	NC
DOS_versus_R2L	4454.58	28073.79	NC
DOS_versus_U2R	3848.97	24774.03	NC
normal_versus_PRB	468.75	6011.70	NC
normal_versus_R2L	364.66	4773.09	14703.55
normal_versus_U2R	295.64	4785.66	14635.36

Cluster ATLAS: 12 nodos

- Microprocessors: 2 x Intel E5-2620 (6 cores/12 threads, 2 GHz)
- RAM 64 GB DDR3 ECC 1600MHz
- Mahout version 0.8

Mahout



Scalable machine learning and data mining

Apache Mahout has implementations of a wide range of machine learning and data mining algorithms: clustering, classification, collaborative filtering and frequent pattern mining

Caso de estudio: Random Forest para KddCup99

Clase	Nº de instancias
normal	972.781
DOS	3.883.370
PRB	41.102
R2L	1.126
U2R	52

Tabla 2: Número de instancias por clase

	10%	50%	full
DOS_versus_normal	6344.42	49134.78	NC
DOS_versus_PRB	4825.48	28819.03	NC

Tiempo en segundos para Big Data con 20 particiones

Datasets	RF-BigData		
	10%	50%	full
DOS_versus_normal	98	221	236
DOS_versus_PRB	100	186	190
DOS_versus_R2L	97	157	136
DOS_versus_U2R	93	134	122
normal_versus_PRB	94	58	72
normal_versus_R2L	92	39	69
normal_versus_U2R	93	52	64

Cluster ATLAS: 12 nodos

- Microprocessors: 2 x Intel E5-2620 (6 cores/12 threads, 2 GHz)
- RAM 64 GB DDR3 ECC 1600MHz
- Mahout version 0.8


Mahout



Scalable machine learning and data mining

Apache Mahout has implementations of a wide range of machine learning and data mining algorithms: clustering, classification, collaborative filtering and frequent pattern mining

Caso de estudio: Random Forest para KddCup99




Mahout




Caso de estudio: Random Forest para KddCup99

Implementación RF Mahout Partial: Es un algoritmo que genera varios árboles de diferentes partes de los datos (maps). Dos fases:

Fase de Construcción



Fase de Clasificación






Nuestro grupo de investigación trabaja en:


Conjuntos no-balanceados Big Data

Multiclasificadores
Pesos en instancias



Generación de prototipos Para Big Data

Algoritmos evolutivos
Modelos de reducción de
prototipos



Mahout vs Nuevas herramientas

Herramienta comercial

<http://www.pentahobigdata.com/>



NIMBLE
(IBM researchers)
ACM SIGKDD, 2011

SystemML
(IBM researchers, DML language,
100-core Amazon EC2)
ICDE 2011

Ricardo
(IBM researchers, Amazon EC2)
R and hadoop
ACM SIGMOD , 2010.

Rhipe
(Purdue University, 2012)
R and hadoop
www.rhipe.org/
<http://www.datadr.org/>


Outline

- ¿Qué es Big Data?
- MapReduce: Paradigma de Programación para Big Data (Google)
- Plataforma Hadoop (Open access)
- Librería Mahout para Big Data. Otras librerías
- **Limitaciones de MapReduce**
- Comentarios Finales



¿Qué algoritmos puedo encontrar para Hadoop?

Analizamos 10 algoritmos muy conocidos



Decision trees (C4.5, Cart) (MReC4.5)
K-Means
SVM
Apriori
kNN
Naïve Bayes
EM (Expectation Maximization)
PageRank
Adaboost

} No disponibles

Limitaciones de MapReduce

Palit, I., Reddy, C.K., 2012. *Scalable and parallel boosting with mapReduce*. IEEE TKDE 24 (10), pp. 1904-1916.

(Amazon EC2 cloud, CGL-MapReduce: (modelos de un paso e iterativos de MapReduce)



Limitaciones de MapReduce

"If all you have is a hammer, then everything looks like a nail."



Los siguientes tipos de algoritmos son ejemplos en los que MapReduce no funciona bien:

**Iterative Graph Algorithms
Gradient Descent
Expectation Maximization**



Limitaciones de MapReduce

Algoritmos de grafos iterativos. Existen muchas limitaciones para estos algoritmos.

Ejemplo: Cada iteración de PageRank se corresponde a un trabajo de MapReduce.

Se han propuesto una serie de extensiones de MapReduce o modelos de programación alternativa para acelerar el cálculo iterativo:

Pregel (Google)

Pregel: A System for Large-Scale Graph Processing

Implementación: <http://www.michaelnielsen.org/ddi/pregel/>


Limitaciones de MapReduce

MapReduce inside Google

Googlers' hammer for 80% of our data crunching

- Large-scale web search indexing
 - Clustering problems for Google News
 - Produce reports for popular queries, e.g. Google Trend
 - Processing of satellite imagery data
 - Language model processing for statistical machine translation
 - Large-scale machine learning problems
 - Just a plain tool to reliably spawn large number of tasks
 - e.g. parallel data backup and restore


The other 20%? e.g. [Pregel](#)



Limitaciones de MapReduce



GIRAPH (APACHE Project)
<http://giraph.apache.org/>
Procesamiento iterativo de grafos



GPS - A Graph Processing System, (Stanford)
<http://infolab.stanford.edu/gps/>
para Amazon's EC2



Distributed GraphLab
(Carnegie Mellon Univ.)
<https://github.com/graphlab-code/graphlab>
Amazon's EC2



Spark (UC Berkeley)
(Se publicita 100 veces más
rápido que Hadoop e incluye algoritmos iterativos)
<http://spark.incubator.apache.org/research.html>



Twister (Indiana University)
<http://www.iterativemapreduce.org/>
Clusters propios



**PrIter (University of
Massachusetts Amherst,
Northeastern University-China)**
<http://code.google.com/p/priter/>
Cluster propios y Amazon EC2 cloud



HaLoop
(University of Washington)
<http://clue.cs.washington.edu/node/14>
<http://code.google.com/p/haloop/>
Amazon's EC2

GPU based platforms

Mars
Grex



Outline

- ¿Qué es Big Data?
- MapReduce: Paradigma de Programación para Big Data (Google)
- Plataforma Hadoop (Open access)
- Librería Mahout para Big Data. Otras librerías
- Limitaciones de MapReduce
- **Comentarios Finales**



Comentarios Finales



Desafíos en Big Data

- Requisitos de rendimiento para el algoritmo
 - Tradicionalmente, los algoritmos "eficientes"
 - Se ejecutan **en tiempo polinomial** (pequeño): $O(n \log n)$
 - Utilizar **el espacio lineal**: $O(n)$
 - Para grandes conjuntos de datos, los algoritmos eficientes
 - Deben ejecutarse **en el tiempo lineal** o incluso **sublineal**: $O(n)$
 - Deben utilizar hasta **espacio polilogarítmico**: $(\log n)^2$
- Limpieza Big Data
 - Ruido y datos distorsionados
 - Resultados de cómputo
 - Resultados de búsqueda
 - Necesidad de métodos automáticos para la "limpieza" de los datos
 - Eliminación de duplicados
 - Evaluación de la calidad
- Modelo de computación
 - Precisión y aproximación
 - Eficiencia

Comentarios Finales

BIG DATA

Oportunidades en Big Data

Oportunidad científica: Big Data es un área emergente y en expansión.


Las posibilidades de desarrollo de algoritmos para nuevos datos, aplicaciones reales ... es un nicho de investigación y desarrollo en los próximos años.



Comentarios Finales

**BIG
DATA**

Oportunidades en Big Data



Comentarios Finales




Oportunidades en Big Data

Oportunidad profesional: En 2015, Gartner predice que 4,4 millones de empleos serán creados en torno a big data. (Gartner, 2013)

Gartner

Fuente: <http://www.gartner.com/technology/topics/big-data.jsp>





**BIG
DATA**

