



Universidad  
de Huelva

# Ciencia de Datos y herramientas Big Data para la Investigación

---

TÉCNICAS AVANZADAS PARA EL ANÁLISIS INTELIGENTE DE DATOS

Prof. Dr. Gualberto Asencio Cortés

<http://datalab.upo.es/asencio>  
[guaasecor@upo.es](mailto:guaasecor@upo.es)



# Contenidos

---

## **BLOQUE I: Análisis exploratorio de datos**

Tema 1: Introducción a la ciencia de datos

Tema 2: Adquisición y visualización de datos

Tema 3: Análisis de la distribución de los datos

## **BLOQUE II: Preprocesado de datos**

Tema 4: Preprocesado de datos

Tema 5: Selección de atributos

## **BLOQUE III: Aprendizaje no supervisado**

Tema 6: Técnicas de clustering

Tema 7: Extracción de reglas de asociación

## **BLOQUE IV: Aprendizaje supervisado**

Tema 8: Técnicas de clasificación

Tema 9: Técnicas de regresión

# TEMA 1. INTRODUCCIÓN A LA CIENCIA DE DATOS

---

# Contenidos

---

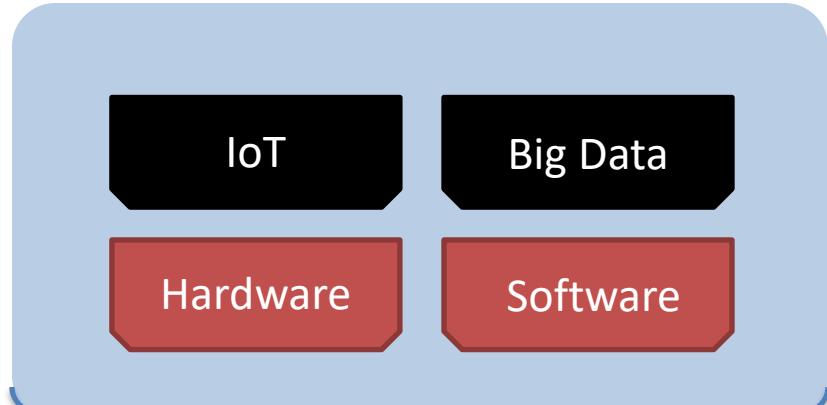
- I. Ciencia de datos
- II. Conceptos básicos
- III. Metodología
- IV. Orange

# I. Ciencia de datos – Diagrama de conceptos clave

- Plano técnico

- Elaboración propia

(Prof. Dr. Gualberto Asencio Cortés)



Computer Science

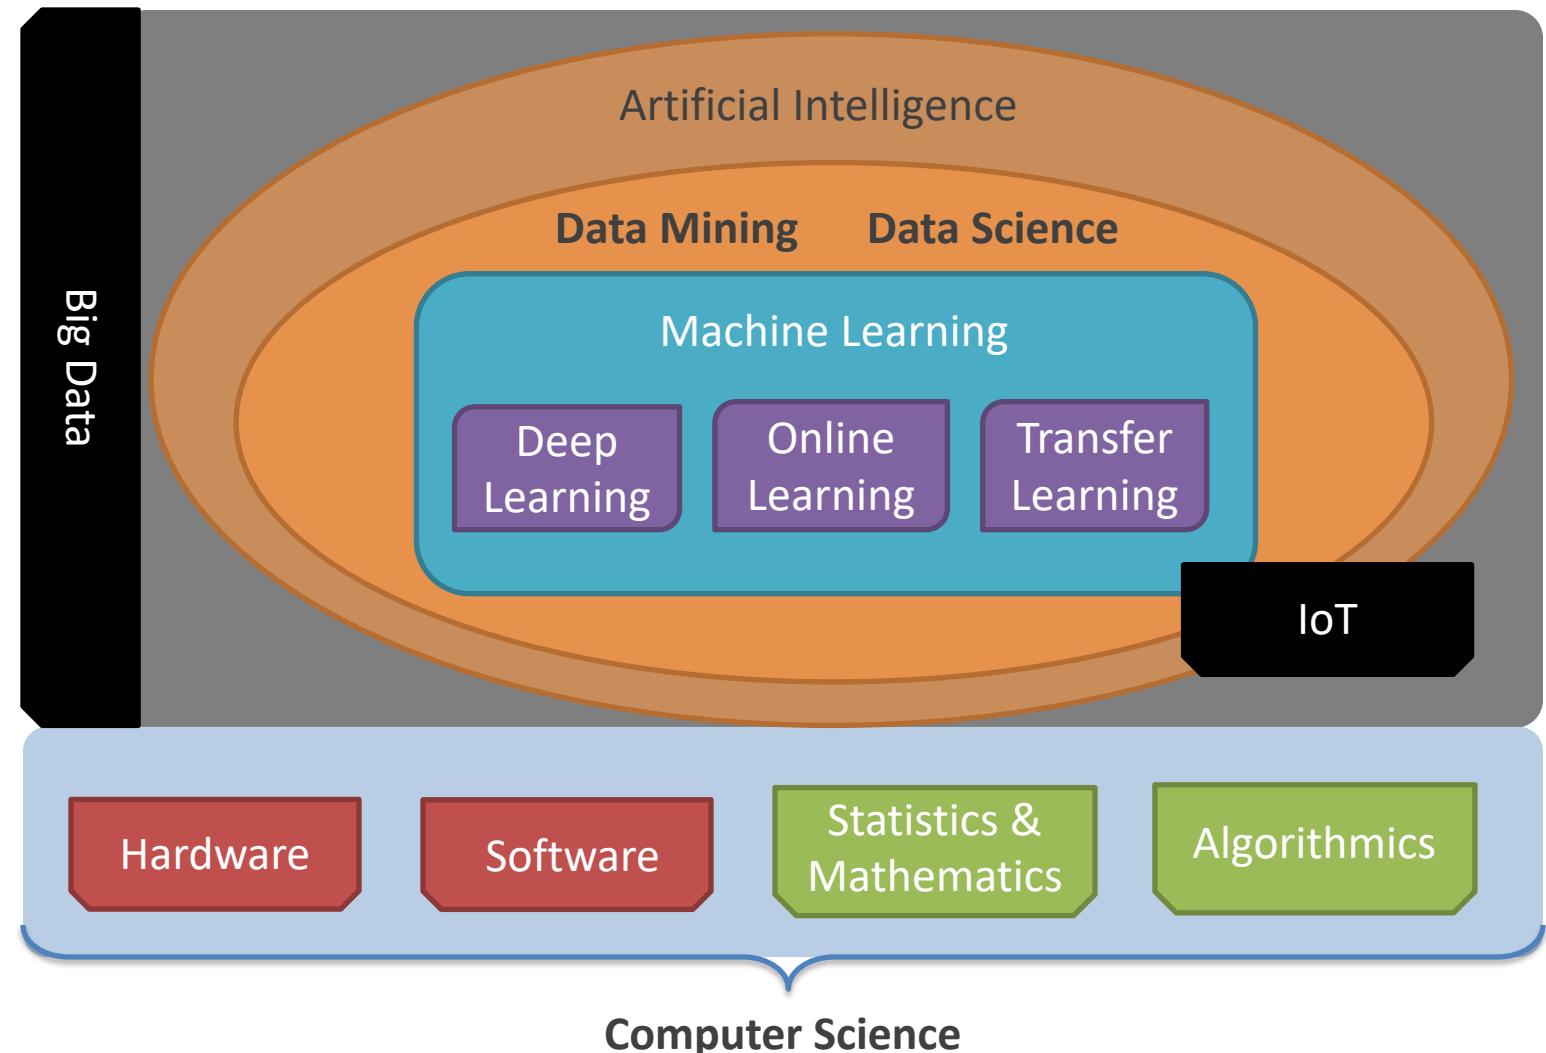
Data Science

# I. Ciencia de datos – Diagrama de conceptos clave

- Plano comercial

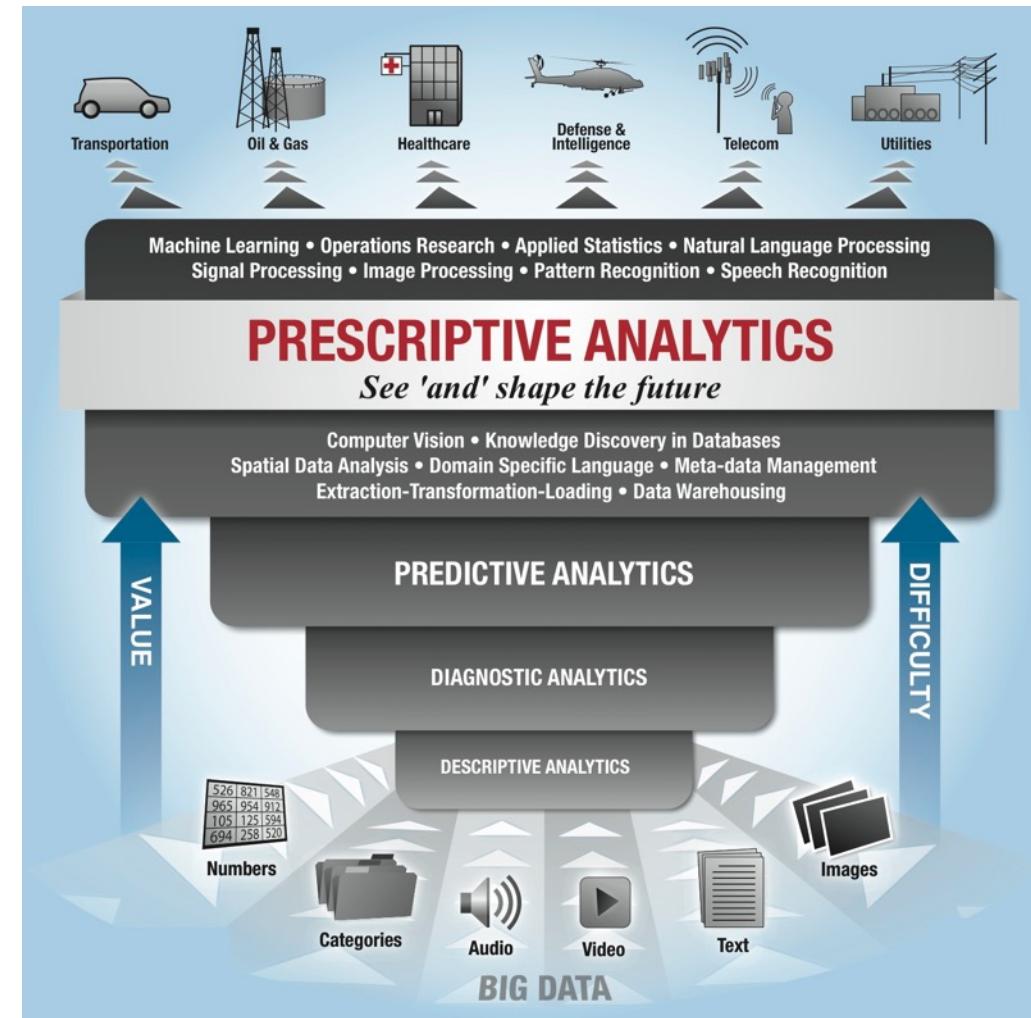
- Elaboración propia

(Prof. Dr. Gualberto Asencio Cortés)



# I. Ciencia de datos – Proyección futura

- Proyección futura del aprendizaje automático



# I. Ciencia de datos – Científico de datos

---

- Es la ciencia que estudia la **extracción de conocimiento** a partir de los datos para obtener información valiosa.
- Roles: el **científico de datos** debe dominar:
  - Tecnologías informáticas
  - Matemáticas y estadística
  - Dominio del problema
  - Capacidad analítica y comunicativa



# I. Ciencia de datos – Retos

---

## ¿Qué retos podemos abordar?

- Encontrar **perfiles** de clientes fraudulentos (evasión de pagos e impuestos)
- Descubrir **relaciones** implícitas entre síntomas y enfermedades de pacientes de un hospital
- Determinar **relaciones** entre especificaciones técnicas de máquinas, archivos de registro y diagnóstico de errores en fábricas o centros de datos
- **Predecir** el consumo eléctrico en un edificio a varios días-vista
- Estimar la **probabilidad** de que los clientes de una empresa se vayan a la competencia
- Determinar **patrones** de compra de clientes de un supermercado y **recomendar** productos atractivos a clientes en función de lo que compran
- **Segmentar** clientes de forma automática para definir diferentes objetivos de mercado y dirigir campañas de marketing específicas a cada segmento
- ....

# I. ¿Qué es Machine Learning?

- Machine Learning = Aprendizaje Automático

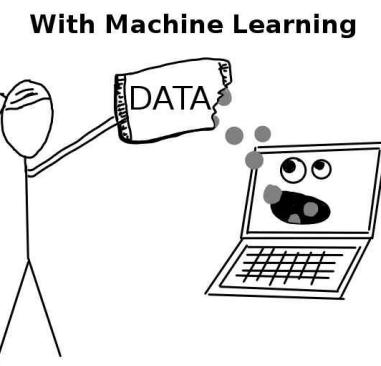
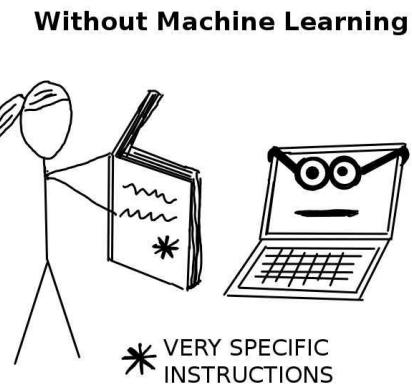
- Programación tradicional:

*Automatizar una tarea usando reglas predefinidas*



- Machine Learning: (Idea General)

*Creación automática de reglas*



# II. Conceptos básicos

---

## ■ Dataset o conjunto de datos:

- Filas (ejemplos, instancias, puntos, observaciones, muestras) (*instances*)
- Columnas (atributos, características) (*features*)

## ■ Tipos de datos de las columnas:

- Valor numérico: valores continuos (cuantitativos)
- Valor texto o etiquetas: valores discretos (cualitativos)

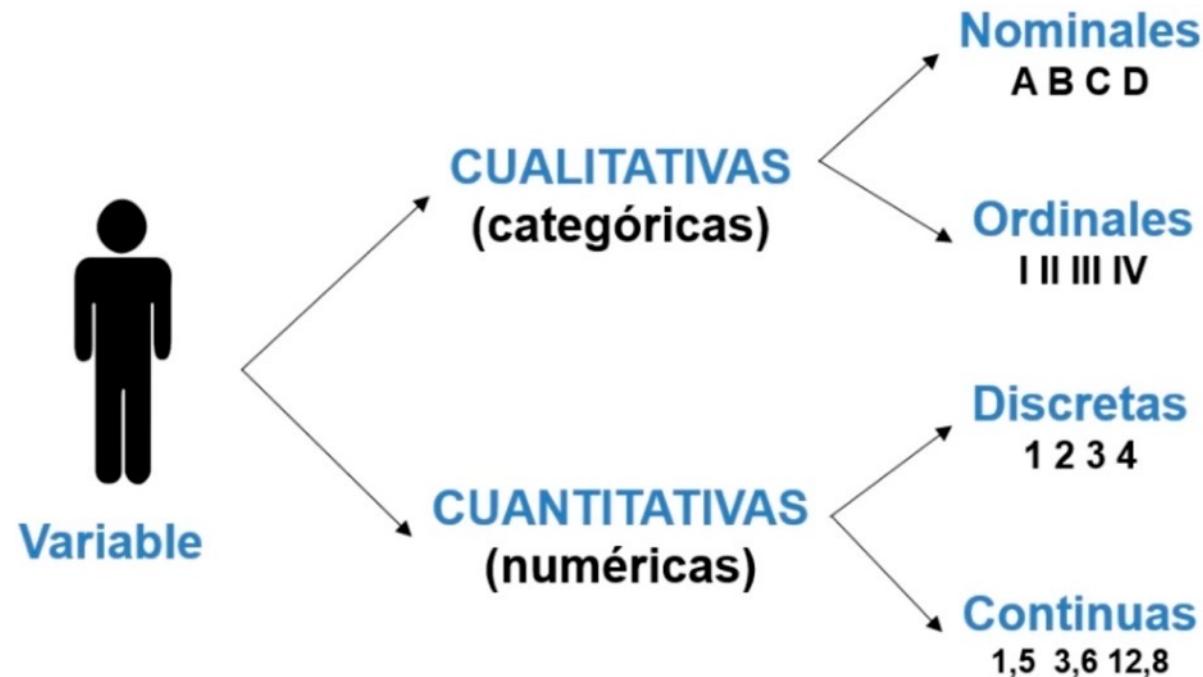
## ■ Última columna (opcional): Clase (atributo de decisión)

# II. Conceptos básicos

Atributos o características					Clase
Ejemplo o Instancia	Longitud sépalo (cm)	Anchura sépalo (cm)	Longitud pétalo (cm)	Anchura pétalo (cm)	Clase (Tipo de Flor)
	5.1	3.5	1.4	0.2	Iris-setosa
	4.4	3.2	1.3	0.2	Iris-setosa
	7.0	3.2	4.7	1.4	Iris-versicolor
Valor numérico o continuo	6.4	3.2	4.5	1.5	Iris-versicolor
	6.3	3.3	6.0	2.5	Iris-virginica
	5.8	2.7	5.1	1.9	Iris-virginica

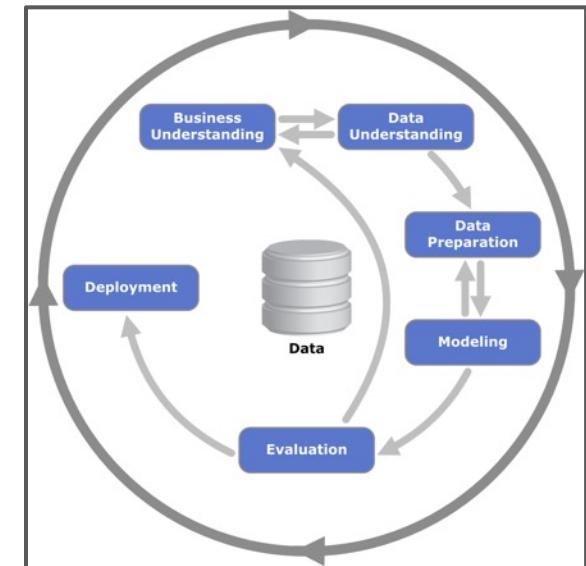
# II. Conceptos básicos

---



# III. Metodología

- Metodología para realizar un proyecto de minería de datos.
- **CRISP-DM:**
  1. Comprensión del negocio
  2. Comprensión de los datos
    - Análisis exploratorio de datos
  3. Preparación de los datos
    - Extracción, transformación y carga (ETL)
    - Preprocesado de datos
  4. Modelado
    - Aprendizaje automático (machine learning)
  5. Evaluación de negocio
  6. Despliegue

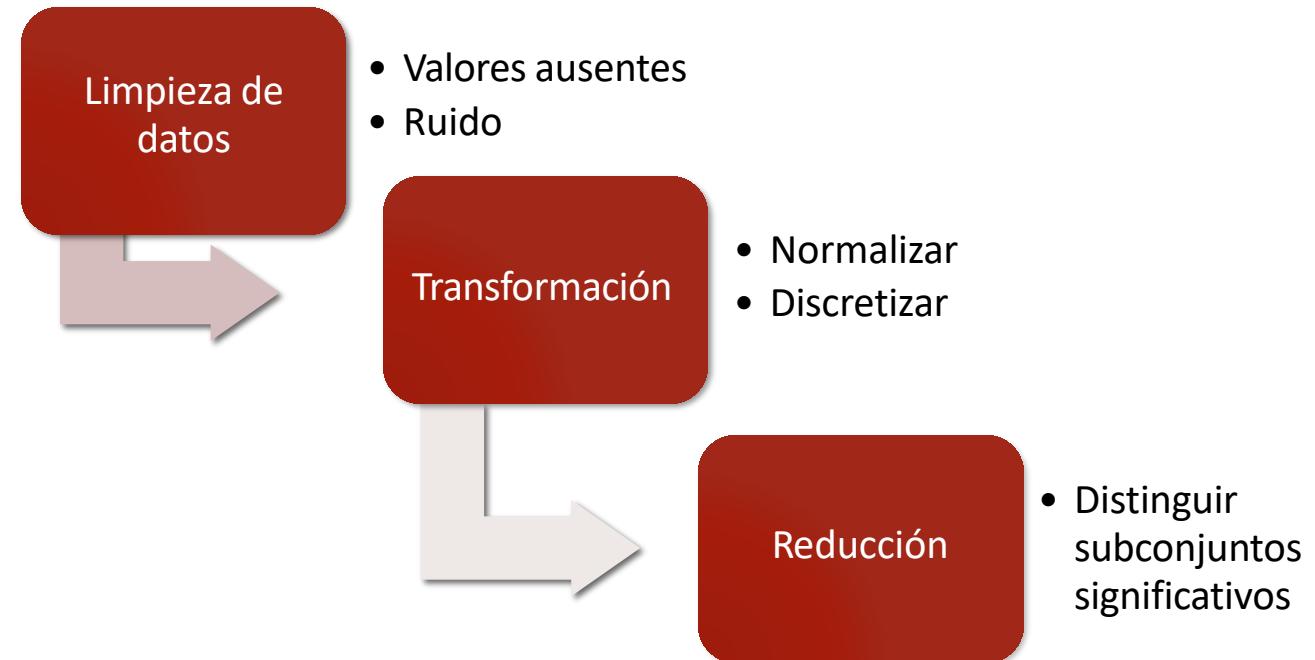


<http://crisp-dm.eu>

# III. Metodología: Preparación de los datos

---

- Ambigüedades, ruido o no estar en el formato adecuado
- Acelera el algoritmo de aprendizaje
- Mejora la calidad del modelo de conocimiento



# III. Metodología: Aprendizaje

---

## Aprendizaje supervisado:

- Conjunto de datos previamente clasificado, etiquetado o con un valor numérico asociado.
- Objetivo: Predecir una clase, etiqueta o valor numérico.

## Aprendizaje no supervisado:

- Conjunto de datos sin clases, etiquetas o valores numéricos asociados.
- Objetivo: Comprender, resumir, agrupar y encontrar relaciones entre las variables.

# III. Metodología: Aprendizaje

## Aprendizaje supervisado

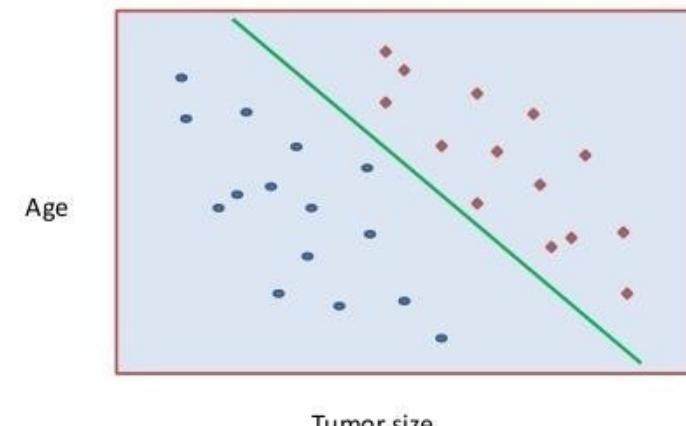
### ■ Regresión

- Predice un dato cuantitativo.
- Predicción consumo



### ■ Clasificación

- Predice una etiqueta o clase cualitativa.
- Detección de un determinado tipo de tumor → {benigno, maligno} en función de la edad, tamaño del tumor, densidad, uniformidad de tamaño y forma de célula, etc.



# III. Metodología: Aprendizaje

## Aprendizaje supervisado

### Regresión

Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Root.Length
5,0	3,5	1,6	0,6	0,8
4,9	2,4	3,3	1,0	0,3
6,1	2,6	5,6	1,4	0,5
6,1	2,9	4,7	1,4	1,3
4,9	2,5	4,5	1,7	0,6
6,7	3,0	5,0	1,7	1,1
5,9	3,0	5,1	1,8	0,3
5,1	3,3	1,7	0,5	0,5
5,0	3,5	1,6	0,6	0,6
4,9	2,4	3,3	1,0	0,9
...	...	...	...	...
6,2	2,9	4,3	1,3	??
6,3	2,3	4,4	1,3	??
7,7	3,8	6,7	2,2	??
4,8	3,4	1,9	0,2	??

PREDICCIÓN
0,4
0,3
0,9
0,7

### Clasificación

Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
5,0	3,5	1,6	0,6	setosa
4,9	2,4	3,3	1,0	versicolor
6,1	2,6	5,6	1,4	virginica
6,1	2,9	4,7	1,4	versicolor
4,9	2,5	4,5	1,7	virginica
6,7	3,0	5,0	1,7	versicolor
5,9	3,0	5,1	1,8	virginica
5,1	3,3	1,7	0,5	setosa
5,0	3,5	1,6	0,6	setosa
4,9	2,4	3,3	1,0	versicolor
...	...	...	...	...
6,2	2,9	4,3	1,3	??
6,3	2,3	4,4	1,3	??
7,7	3,8	6,7	2,2	??
4,8	3,4	1,9	0,2	??

CLASE
versicolor
versicolor
virginica
setosa

# III. Metodología: Aprendizaje

## Aprendizaje no supervisado

### ■ Clustering

- Agrupación de un conjunto de datos (no etiquetados) en grupos de objetos llamados cluster.
- Cada cluster está formado por una colección de objetos que son similares (o se consideran similares) entre sí, pero que son distintos respecto a los objetos de otros clusters.



### ■ Reglas de asociación

- Búsqueda de relaciones dentro del conjunto de datos. Establecer las posibles relaciones o correlaciones entre distintas acciones o sucesos aparentemente independientes;
- pudiendo reconocer como la ocurrencia de un suceso o acción puede inducir o generar la aparición de otros.



# III. Metodología: Evaluación

---

## Evaluación:

- Para saber cómo de bueno o malo es el modelo aprendido.
- Medidas:
  - Problemas de **regresión**: diferencia entre valor predicho y valor real.
  - Problemas de **clasificación**: tasa de error.
    - Éxito: La clase de la instancia es predicha correctamente.
    - Error: La clase de la instancia es predicha incorrectamente.
    - Tasa de error: proporción de errores cometidos sobre el conjunto entero de instancias.

# III. Metodología: Evaluación

---

## Conjunto de datos para la evaluación:

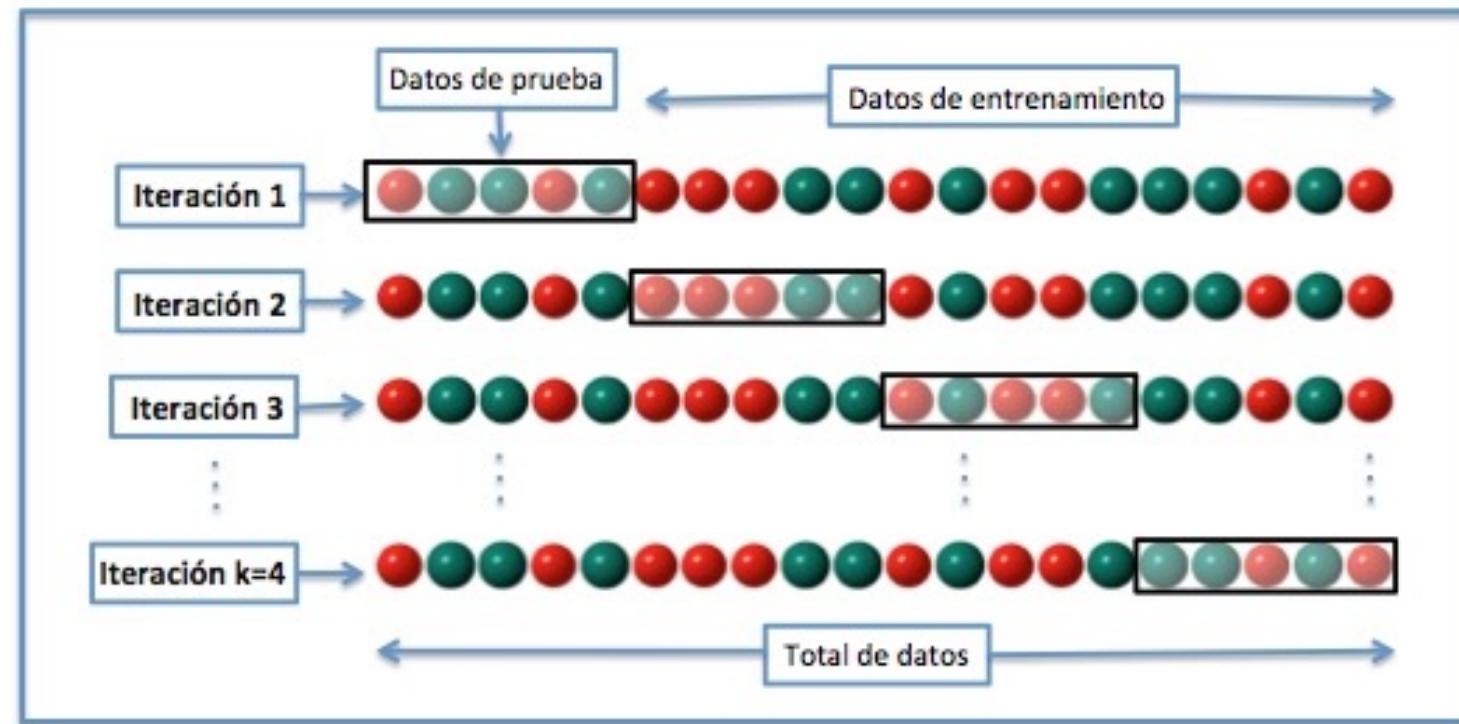
- Debe ser distinto al conjunto de entrenamiento ya que el error que se produzca al clasificar o predecir no es un buen indicador, puede haber sobreajuste del modelo.
- Sets:
  - Training: Entrenamiento de los modelos.
  - Validation: Ajustar los hiperparámetros del modelo con el objetivo de seleccionar el mejor modelo.
  - Test: Evaluación del modelo con registros con los que no se ha entrenado ni ajustado el modelo.

## Validación del modelo:

Método hold-out, validación cruzada, leave-one-out, etc.

# III. Metodología: Validación

## Validación cruzada



# Actividad 1

---

Queremos resolver cada uno de los dos siguientes problemas:

**Problema 1:** Un supermercado quiere saber el número de productos de un determinado tipo que se venderán la próxima semana.

**Problema 2:** Un servicio de telefonía quiere saber si un determinado cliente se va a ir a la competencia.

**¿clasificación o regresión?**

- a) Ambos como problemas de clasificación.
- b) El problema 1 como un problema de clasificación y problema 2 como un problema de regresión.
- c) El problema 1 como un problema de regresión y problema 2 como un problema de clasificación.
- d) Ambos como problemas de regresión.

# Actividad 1

---

Queremos resolver cada uno de los dos siguientes problemas:

**Problema 1:** Un supermercado quiere saber el número de productos de un determinado tipo que se venderán la próxima semana.

**Problema 2:** Un servicio de telefonía quiere saber si un determinado cliente se va a ir a la competencia.

**¿clasificación o regresión?**

- a) Ambos como problemas de clasificación.
- b) El problema 1 como un problema de clasificación y problema 2 como un problema de regresión.
- c) El problema 1 como un problema de regresión y problema 2 como un problema de clasificación.
- d) Ambos como problemas de regresión.

# Actividad 2

---

Queremos resolver cada uno de los dos siguientes problemas:

**Problema 1:** Un supermercado quiere saber cuáles son los productos que compran los clientes frecuentemente.

**Problema 2:** Un servicio de telefonía quiere conocer los grupos de clientes según sus perfiles de consumo.

**¿clustering o asociaciones?**

- a) Ambos como problemas de clustering.
- b) El problema 1 como un problema de clustering y el problema 2 como un problema de reglas de asociación.
- c) El problema 1 como un problema de reglas de asociación y el problema 2 como un problema de clustering.
- d) Ambos como problemas de reglas de asociación.

# Actividad 2

---

Queremos resolver cada uno de los dos siguientes problemas:

**Problema 1:** Un supermercado quiere saber cuáles son los productos que compran los clientes frecuentemente.

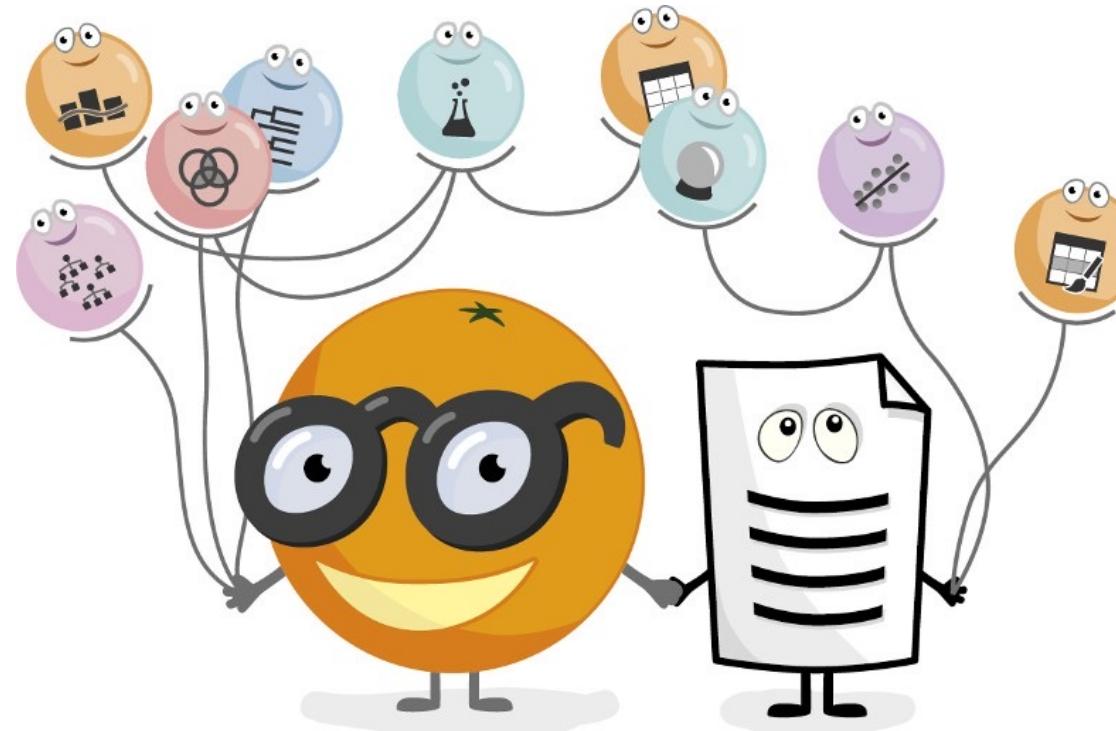
**Problema 2:** Un servicio de telefonía quiere conocer los grupos de clientes según sus perfiles de consumo.

**¿clustering o asociaciones?**

- a) Ambos como problemas de clustering.
- b) El problema 1 como un problema de clustering y el problema 2 como un problema de reglas de asociación.
- c) El problema 1 como un problema de reglas de asociación y el problema 2 como un problema de clustering.
- d) Ambos como problemas de reglas de asociación.

# IV. Orange

orange



orange

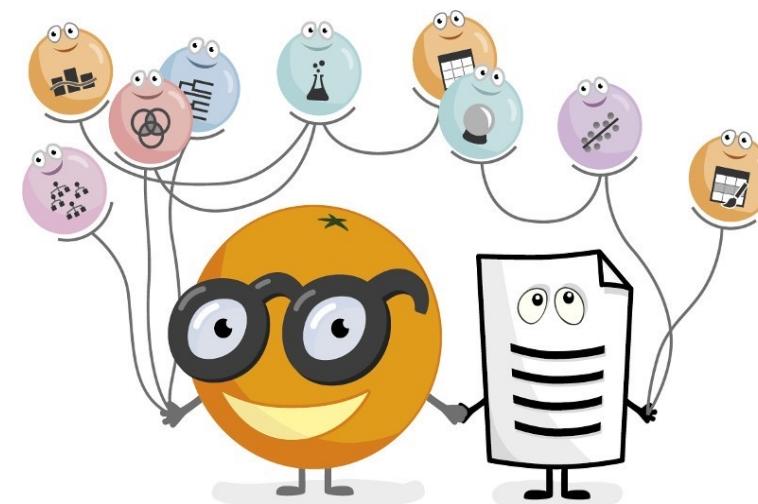
*Copyright: Copyright © University of Ljubljana*

# IV. Orange



Orange es un entorno de trabajo que integra una colección de algoritmos de ciencias de datos.

- **Herramientas** para preprocesamiento, clasificación, regresión, clustering, reglas de asociación y visualización.
- Cuenta con un **interfaz visual** muy fácil de usar que evita tener que programar las aplicaciones para nuestros experimentos.
- No se necesita saber **programar**.
- Software open-source y gratuito.
- Descarga: <https://orangedatamining.com>



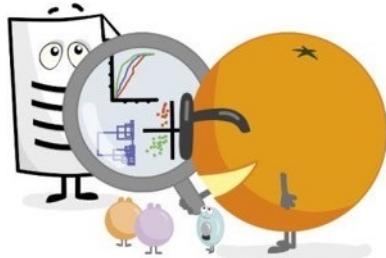
*Copyright: Copyright © University of Ljubljana*

# IV. Orange



Características:

**1) Visualización interactiva**



**2) Programación visual**



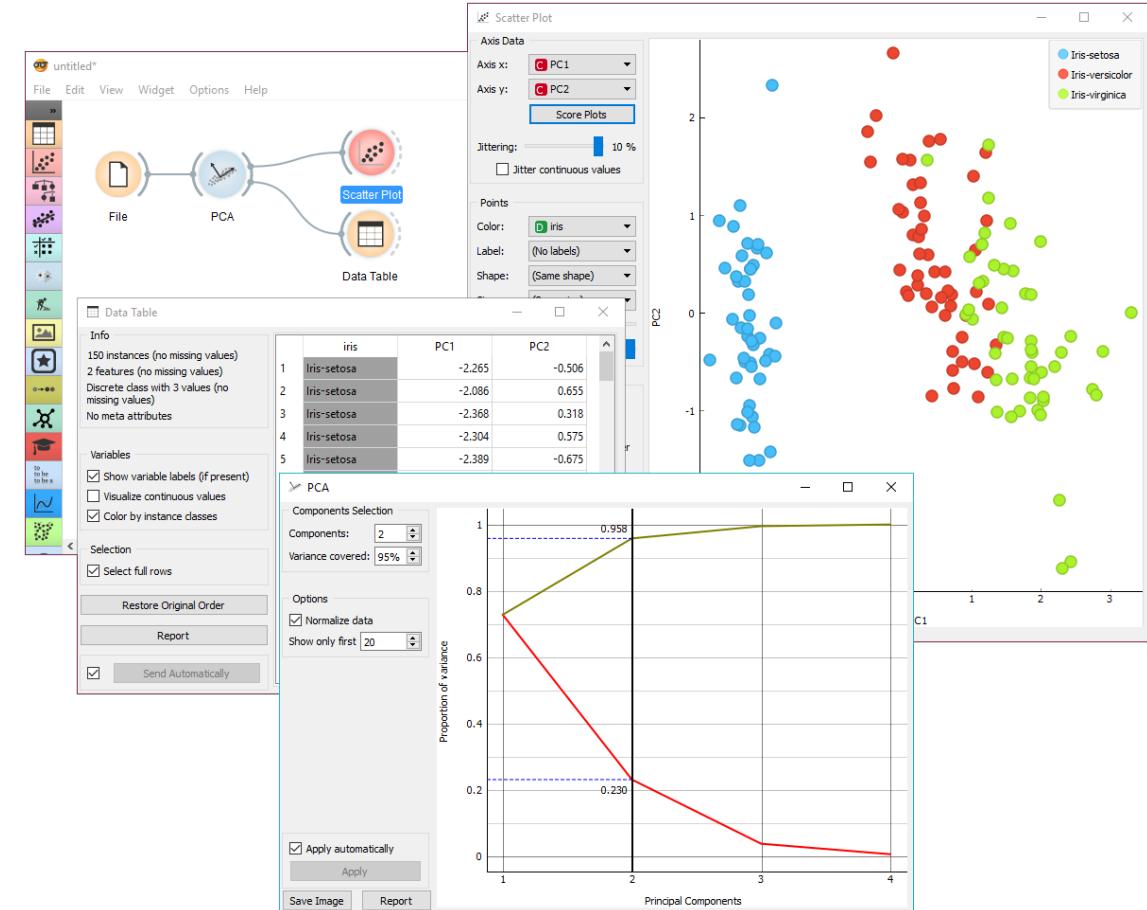
**3) Add-ons**



# IV. Orange – Visualización interactiva



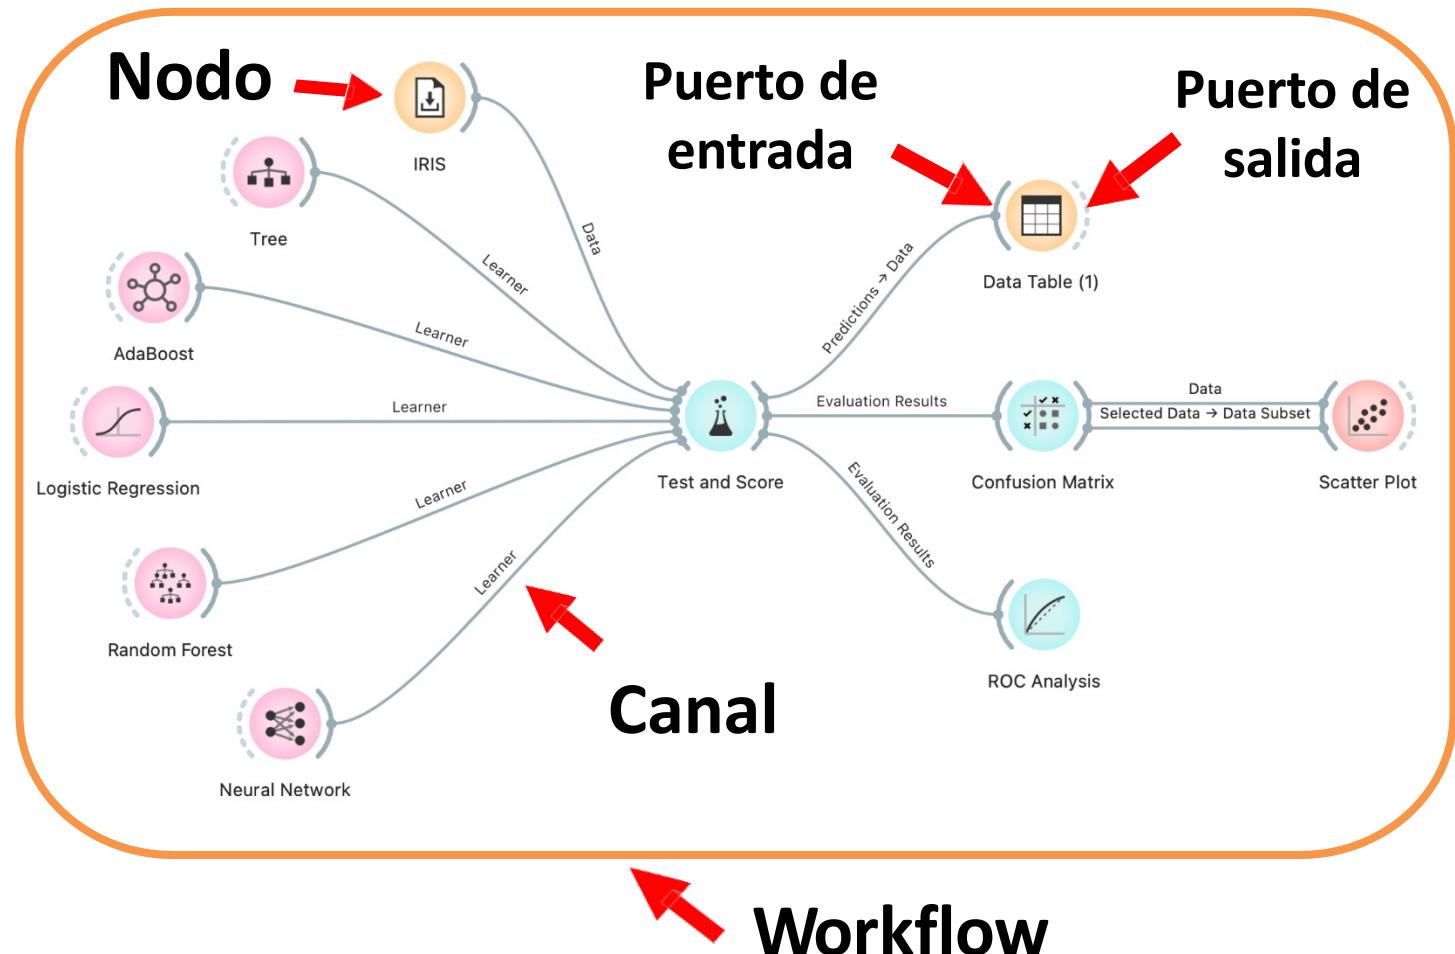
- Visualizaciones interactivas muy potentes
- Análisis exploratorio de los datos
- Visualizaciones inteligentes
- Informes



# Orange – Programación Visual



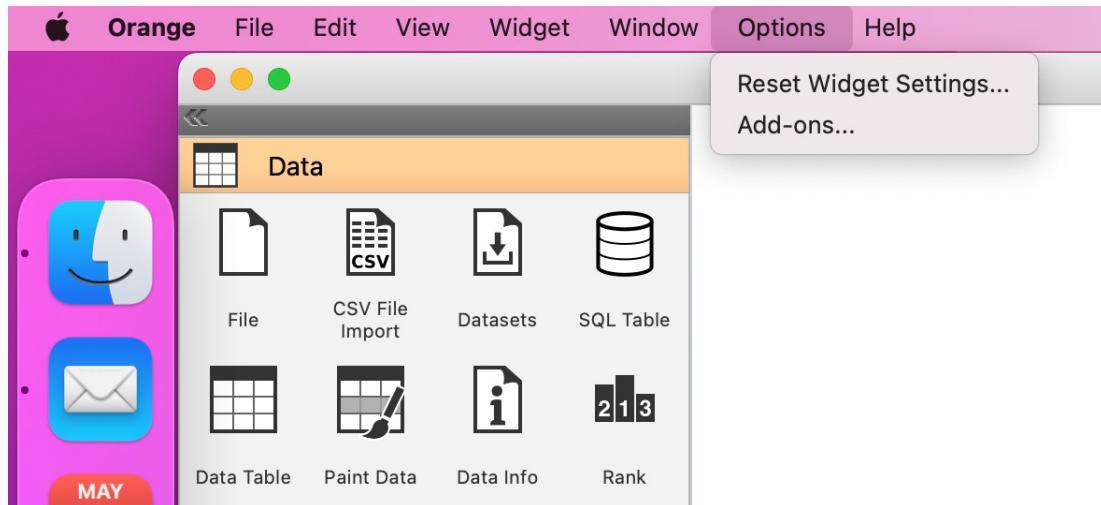
- Análisis de los datos de forma interactiva
- Minería de Datos basada en **nodos**
- Los nodos se comunican con **canales** a través de **puertos** de entrada y salida.
- Programación basada en flujos de trabajo (**workflows**)



# Orange – Add-ons



## Instalación de paquetes desde el gestor de paquetes



Installer

Filter... Add more...

Name	Version	Action
Orange3	3.32.0	<input checked="" type="checkbox"/>
Associate	1.1.9	<input checked="" type="checkbox"/>
Bioinformatics	4.5.0	<input type="checkbox"/>
Educational	0.5.0	<input checked="" type="checkbox"/>
Explain	0.5.3	<input checked="" type="checkbox"/>
Geo	0.3.0	<input checked="" type="checkbox"/>
Image Analytics	0.8.0	<input checked="" type="checkbox"/>
Network	1.6.0	<input checked="" type="checkbox"/>
Prototypes	0.17.0	<input checked="" type="checkbox"/>
Single Cell	1.5.0	<input type="checkbox"/>
Spectroscopy	0.6.5	<input type="checkbox"/>
Text	1.7.0	<input type="checkbox"/>
Textable	3.1.11	<input type="checkbox"/>
Timeseries	0.3.12	<input checked="" type="checkbox"/>
Survival Analysis	0.4.0	<input type="checkbox"/>
World Happiness	0.1.2	<input type="checkbox"/>

### Orange 3

Orange is a component-based data mining software. It includes a range of data visualization, exploration, preprocessing and modeling techniques. It can be used through a nice and intuitive user interface or, for more advanced users, as a module for the Python programming language.

This is the latest version of Orange (for Python 3). The deprecated version of Orange 2.7 (for Python 2.7) is still available ([binaries](#) and [sources](#)).

#### Installing with pip

To install Orange with pip, run the following.

```
# Install some build requirements via your system's package manager
sudo apt install virtualenv build-essential python3-dev

# Create a separate Python environment for Orange and its dependencies ...
virtualenv --python=python3 --system-site-packages orange3venv
# ... and make it the active one
source orange3venv/bin/activate
```

Cancel OK