

TEMA 3. ANÁLISIS DE LA DISTRIBUCIÓN DE LOS DATOS

Contenidos

- I. Introducción
- II. Distribuciones marginales
 - a. Data Table
 - b. Feature Statistics
 - c. Distributions
 - d. Box Plot
- III. Distribuciones conjuntas
 - a. Scatter Plot
 - b. Line Plot
 - c. Correlations, Distances, Distance Matrix y Distance Map
 - d. Heat Map
- IV. Actividad

I. Introducción

Tipos de análisis de la distribución de los datos

- **Univariante:** distribuciones marginales
- **Multivariante:** distribuciones conjuntas (condicionales)
 - Caso particular: análisis bivariante (dos variables)

Representación del análisis

- **Análisis cuantitativo:** tablas numéricas (estadísticas, ...)
- **Visualización gráfica:** gráficos de diferentes tipos


II. Distribuciones marginales

Data Table

- Objetivo: observar la distribución de los valores de los atributos **sin resumir** (previa ordenación por columna).
- Información del tamaño del dataset, el número y los tipos de atributos.
- Permite visualizar una barra horizontal de rango en atributos numéricos coloreada en función de una clase discreta.
- Se pueden seleccionar **filas** para comunicarlas con otros nodos.




Data Table



II. Distribuciones marginales

Feature Statistics

- Objetivo: visualizar mediante histogramas.
- Se pueden colorear según el atributo seleccionado. Si es numérico se usará una paleta continua de colores.
- Estadísticos numéricos descriptivos de cada atributo.
 - Centro: Si son atributos numéricos es la media, si son cualitativos es la moda.
 - Dispersion: Si son atributos numéricos es el coeficiente de variación, si son cualitativos es la entropía.
- Se pueden seleccionar **atributos** para comunicarlos con otros nodos.



II. Distribuciones marginales

Distributions


- Objetivo: visualizar un histograma para cada atributo.
- Cambiar tamaño de las barras y la distribución.
- Permite ajustar una distribución de probabilidad en función de cada valor de un atributo cualitativo (**Split by**).
- Se pueden seleccionar **filas** para comunicarlas con otros nodos.



II. Distribuciones marginales

Box Plot


- Objetivo: visualizar los valores mínimo, máximo, media y cuartiles de cada atributo, así como un test de contraste de diferencia de medias con respecto a un atributo (clase) cualitativo.
 - Media: Raya azul oscuro vertical.
 - Mediana: Raya amarilla vertical.
 - Valores entre 1º y 3º cuartil: Zona azul.
- “Annotate”: Muestra los valores finales.
- Se pueden seleccionar **filas** para comunicarlas con otros nodos.



III. Distribuciones conjuntas

Scatter Plot

- Objetivo: visualizar las instancias del dataset proyectadas en 2 dimensiones (2 atributos). Útil para análisis *bivariante*.
- Permite encontrar las proyecciones que mejor discriminan la clase con “Find Informative Projections”.
- Es posible visualizar hasta 6 atributos a la vez (color, forma, tamaño y etiqueta).
- Se pueden seleccionar **filas** para comunicarlas con otros nodos.



III. Distribuciones conjuntas

Line Plot


- Objetivo: visualizar los valores de cada atributo conectados mediante líneas por pertenecer a la misma instancia.
- Permite representar una línea promedio (“Mean”), líneas de percentiles 10% - 90% (“Range”) y barras de desviación típica (“Error”).
- “Group by” para unir instancias según un atributo cualitativo.
- Se pueden seleccionar **filas** para comunicarlas con otros nodos.



III. Distribuciones conjuntas

Correlations, Distances, Distance Matrix y Distance Map




- Objetivo: calcular las correlaciones entre pares de atributos.
- El nodo **Correlations** permite tanto Pearson como Spearman. Devuelve tanto la tabla de correlaciones como el par de atributos seleccionado.
- El nodo **Distances** computa distancias entre filas o entre columnas (normalizando) y permite más tipos de correlaciones (funciones de distancia).
- Los nodos **Distance Matrix** y **Distance Map** permiten visualizar las matrices de distancias.



III. Distribuciones conjuntas

Heat Map

- Objetivo: visualizar todas las instancias del dataset con todos sus atributos, coloreadas por una paleta de colores común y agrupadas según uno o dos atributos cualitativos (o la clase).
- También puede hacer las agrupaciones mediante clustering.
- Permite observar dendrogramas (clustering jerárquico), tanto por filas como por columnas.



IV. Actividad de análisis de distribuciones

1. Cargue el dataset **Hearth Disease** mediante el nodo **Datasets**
2. Utilice los nodos estudiados para analizar las distribuciones marginales.
 - a) Decida que tipos de visualización son más informativos.
 - b) ¿Qué conclusiones puede extraer a partir de la visualización?
3. Utilice los nodos estudiados para analizar las distribuciones conjuntas.
 - a) Escoja los tipos de visualización más apropiados para este dataset.
 - b) ¿Qué conclusiones puede extraer?