

TEMA 4. PREPROCESADO DE DATOS

Contenidos

- I. Introducción
- II. Valores ausentes
- III. Detección de Outliers
- IV. Creación de nuevos atributos
- V. Normalización y estandarización
- VI. Discretización de atributos continuos
- VII. “Continuización” de atributos discretos
- VIII. Preprocesado en Orange
- IX. Actividades

I. Introducción

¿Por qué preprocesar los datos?

Los datos de los problemas reales suelen ser:

- **Datos incompletos:** valores de atributos inexistentes (ausentes/missings)
- **Datos con ruido:** errores de precisión, errores de medición, errores de almacenamiento
- **Datos inconsistentes:** outliers
- **Datos con formato no compatible**
- ...

Para obtener conclusiones válidas y útiles es necesario una adecuada preparación previa de los datos.

II. Valores ausentes

La presencia de datos faltantes o perdidos puede ser un problema que puede conducir a resultados poco precisos:

- Algunos valores ausentes expresan características relevantes
- Datos incompletos

Posibles soluciones:


- Eliminar ejemplos con atributos sin valor: Pérdida de información
- Asignar una constante o un valor aleatorio: Mala interpretación del algoritmo de aprendizaje
- Reemplazar el valor: por medias o modas (demasiado *naive*) o predecir el valor (puede ser costoso)

II. Valores ausentes

Nodo Preprocess

Impute Missing Values

- “Average/Most frequent”: reemplaza los valores ausentes (?) por la media (para valores numéricos) o por la moda (valores cualitativos).
- “Replace with random value”: reemplaza los valores ausentes con valores aleatorios, siempre entre el rango de la variable en cuestión.
- “Remove rows with missing values”: elimina las filas con algún valores ausentes.




II. Valores ausentes

Nodo Preprocess

Remove Sparse Features


- Conserva solo aquellos **atributos** que superan un umbral de porcentaje o valor fijo de valores no nulos (o ceros).
- Hay que tener cuidado al usarlo.



II. Valores ausentes

Nodo Impute


- “Model-based imputer”: Construye un modelo para predecir los valores ausentes basándose en los valores de otros atributos.
 - El modelo por defecto es 1-NN (1-nearest neighbor): toma el valor de la instancia más similar.
- Cada atributo se puede imputar por separado.



III. Detección de outliers

Para la detección de outliers se suelen aplicar técnicas de aprendizaje no supervisado:

- Estimador de covarianza: Ajusta una elipse a los puntos centrales con la distancia Mahalanobis (solo datos con distribución Gaussiana)
- One-class SVM with non-linear kernel (RBF): Clasifica los datos como similares o diferentes. Suele funcionar bien para distribuciones no Gaussianas.
- Isolation Forest: Usa Random Forest: aísla aleatoriamente un atributo y luego selecciona aleatoriamente un valor de división (entre su máximo y mínimo).
- Local Outlier Factor: Usa K-Nearest Neighbors. Algoritmo que mide el grado de anormalidad mediante la desviación de un punto con respecto a sus vecinos.



III. Detección de outliers


Cada método tiene unos parámetros específicos. Por ejemplo el método Local Outlier Factor:

- “Contamination”: Proporción de outliers en los datos.
- “Neighbors”: Número de vecinos a tener en cuenta.
- “Metric”: Métrica para calcular la distancia entre los vecinos.



IV. Creación de nuevos atributos

- Añadir nuevos atributos aplicando expresiones a atributos ya existentes en el conjunto de datos.
- Se pueden crear tanto atributos cuantitativos (por ejemplo usando expresiones en Python) como cualitativos (con sus posibles valores)
- **Nodo Feature Constructor**
- **Nodo Create Class:** Crea un nuevo atributo a partir de un atributo discreto o de texto (indicándolo en “Substring”)



V. Normalización y estandarización

1. Normalización:

- Trasforma el rango de valores a un intervalo determinado (normalmente [0,1]).
- Es necesario si se van a aplicar algoritmos de aprendizaje basados en distancias para que todos los atributos estén en el mismo rango.

$$x_i^N = \left\{ \frac{x_{i,j} - \min(x_i)}{\max(x_i) - \min(x_i)}, \forall j \in 1, \dots, n \right\}$$

$$x = x^N \cdot (\max(x_i) - \min(x_i)) + \min(x_i)$$

2. Estandarización:

- Transforma los valores de los atributos para que tengan media 0 y desviación 1.
- Sólo si la distribución es normal.

$$x_i^S = \left\{ \frac{x_{i,j} - \text{media}(x_i)}{\text{desv}(x_i)}, \forall j \in 1, \dots, n \right\}$$


$$x = x^S \cdot \text{desv}(x_i) + \text{media}(x_i)$$

V. Normalización y estandarización

Nodo Preprocess

Normalize Features

- Ajustar valores a una escala común. Normalización y estandarización.



VI. Discretización de atributos continuos

Algoritmos de aprendizaje que solo operan con atributos discretos:

- Requieren transformación de atributos continuos a discretos.

Consiste en dividir el rango de valores continuos en un conjunto finito de intervalos (o cortes).

Opciones:

- No Supervisado:
 - Igual Anchura: k intervalos de igual anchura
 - Igual Frecuencia: k intervalos de N/k valores
- Supervisado:
 - Fayyad e Irani (basado en criterio de entropía mínima), Kononenko, 1Rules (Clasificación)


VI. Discretización de atributos continuos

No Supervisado:

Ejemplo – Datos: 1, 2, 2'5, 4, 5'5, 6, 7, 7, 7'5, 9


Igual anchura

- Intervalo 1 (<5): 1, 2, 2'5, 4 [0, 5)
- Intervalo 2 (≥ 5): 5'5, 6, 7, 7, 7'5, 9 [5, 10]



Igual frecuencia

- Intervalo 1: 0, 2, 2'5, 4, 5'5 [0, 5'5]
- Intervalo 2: 6, 7, 7, 7'5, 9 (5'5, 10]




VI. Discretización de atributos continuos

Nodo Preprocess


Discretize Continuous Variables

- “Entropy-MDL discretization”: Método supervisado basado en el modelo de Fayyad and Irani para determinar el número de intervalos óptimos.
- “Equal frequency discretization”: Divide dejando el mismo número de instancias en cada intervalo.
- “Equal width discretization”: Crea intervalos con la misma anchura.
- “Remove numeric features altogether”: no recomendado, elimina todos los atributos numéricos




VII. “Continuización” de atributos discretos

- Es el proceso contrario a la discretización.
- Las variables discretas (incluyendo las binarias) se reemplaza por variables continuas.



Color	Red	Yellow	Green
Red	1	0	0
Red	1	0	0
Yellow	0	1	0
Green	0	0	1
Yellow	0	0	1



VII. “Continuización” de atributos discretos

Nodo Preprocess

Continuize Discrete Variables

- “Most frequent as base”: el valor más frecuente se codifica como 0 y los demás como 1.
- “One feature per value”: crea columnas para cada valor y pone 1 donde la instancia tenga ese valor (One Hot Encoding).
- “Remove non-binary features”: se queda solo con las características categóricas que tienen valores de 0 o 1 y las transforma en continuas.
- “Remove categorical features”: elimina todos los atributos categóricos.
- “Treat as ordinal”: toma valores discretos y los trata como números. Si los valores discretos son categorías, cada categoría será asignada a un número en el orden en el que aparecen en los datos.
- “Divide by number of values”: es similar al anterior, pero el número final será dividido por el número total de valores, de esta forma el rango de la nueva columna estará comprendido entre [0,1].

VIII. Preprocesado en Orange

□ Las herramientas de preprocesado en Orange se encuentran en el modulo **Data**.

□ Orange contiene un nodo específico para preprocesamiento **Preprocess** en el que se puede crear un pipeline de preprocesado pulsando y arrastrando componentes.




Preprocess

Ya estudiados:

1. Tratamiento de valores ausentes
2. Normalización y estandarización
3. Discretización y continuización

Más tipos:

4. Selección de atributos relevantes
5. Selección al azar de atributos
6. Aleatorizar instancias: Mezcla los valores de las clases y destruye cualquier conexión existente entre las instancias y las clases
7. Métodos para la reducción de la dimensionalidad: PCA y CUR



IX. Actividad 1: Valores ausentes y outliers

1. Filtros de valores ausentes:

- a) Cargue el fichero "**diabetes_missing.csv**". Es un conjunto de datos con valores ausentes. Las variables o atributos que se miden de cada instancia está en:

https://github.com/gualbe/datasets/blob/main/curso_ciencia_datos/diabetes_missing.csv

Todos los atributos son numéricos menos la clase que es el atributo categórico "Outcome". Realice la importación del fichero indicando los tipos de cada atributo.

- b) Orange detecta los valores ausentes con ? . ¿Cuál es el porcentaje de atributos ausentes en el dataset?
- c) A continuación, veamos cómo podemos evitar los valores ausentes de nuestro conjunto de datos. Una forma sencilla de manejar los datos que faltan es quitar aquellas instancias que tienen uno o más valores ausentes. Podemos hacerlo en Orange utilizando el nodo **Preprocessing** o **Impute**:
- Seleccione el filtro **Impute**.
 - Establezca el método por defecto **Remove Instances with unknown values**.
 - Ejecute y observe si se han eliminado las instancias indicadas visualizando el conjunto de datos transformado. ¿Cuántas instancias tiene el nuevo conjunto de datos?

IX. Actividad 1: Valores ausentes y outliers

- d) Ahora en lugar de eliminar instancias con valores perdidos (no recomendado), vamos a reemplazarlos con otros valores. En este caso vamos a tratar los valores perdidos. Para hacer esto, vamos a usar el filtro **Impute** de nuevo. Es común tratar los valores perdidos con la media de la distribución numérica.
- Seleccione la opción **Average/most frequent**. Ejecute y observe si se han reemplazado los valores indicados visualizando el conjunto de datos transformado.

2. Detección de Outliers:

- Por último, vamos a observar si hay valores que no sigan la tendencia normal de los datos en el conjunto de datos **diabetes**.
- Para hacernos una idea de si habrá o no outliers primero vamos a utilizar un box plot. ¿Qué conclusiones puede sacar?
- Ejecute el nodo **Outliers** con el método “Local Outlier Factor” con 20 vecinos y la distancia euclídea.
- Conecte la salida del nodo con dos Data Table, uno para los outliers y otro para los inliers (seleccionándolo en el canal). ¿Cuántos outliers se han detectado?

IX. Actividad 2: Preprocesado en IRIS

1. Cargue el dataset IRIS

2. Comprobación de datos

- a) Utilice el nodo **Select Columns** y compruebe que los atributos y la clase ("iris") están seleccionados de forma correcta.
- b) Visualice los datos con **Data Table**.

3. Discretización

- a) Utilice el filtro **Discretize** (no supervisado) sobre el conjunto de datos iris. Establezca la propiedad bins a 4 usando intervalos de misma anchura. Visualice el conjunto de datos tras la transformación usando el nodo **Distributions**.
- b) Repita el mismo filtro pero ahora divida el dominio de los atributos en 4 intervalos de la misma frecuencia. Visualice el conjunto de datos tras la transformación y compare los resultados obtenidos con el primer filtro.
- c) Repita el filtro con la propiedad Entropy-MDL discretization a True (**Supervisada**). Visualice el conjunto de datos tras la transformación y compare los resultados obtenidos con el primer filtro.

IX. Actividad 2: Preprocesado en IRIS

4. Filtros de transformación: Atributos calculados, normalización y binarización

- a) Añada dos atributos calculados mediante el nodo **Feature Constructor**: uno que multiplique los atributos relacionados con el sépalo y otro que multiplique los relacionados con el pétalo. Visualice el conjunto de datos tras la transformación realizada con **Scatter Plot**. Analice los resultados obtenidos.
- b) Aplique el filtro **Normalize** en el intervalo [0,1] del nodo **Preprocess** sobre el conjunto de datos generado en el paso anterior. Visualice los resultados con **Scatter Plot**. ¿Qué efecto tiene este filtro?
- c) Transforme los valores de los atributos para que tengan media 0 y desviación 1 utilizando el filtro **Standarize** del nodo **Preprocess**.

5. Selección de instancias:

- a) Aplique el nodo **Select Rows**, que selecciona las instancias de acuerdo a condiciones definidas sobre uno de los atributos. En este caso se desean eliminar las instancias cuya clase sea igual a **Iris-setosa**. Repita el proceso, pero ahora obtenga aquellas instancias con valor superior a 5.2 en el atributo **sepalLength**.
- b) Aplique el filtro **DataSampler** para escoger el 80% de las instancias. Guarde el conjunto de datos resultante como **iris2.csv**