

TEMA 7. EXTRACCIÓN DE REGLAS DE ASOCIACIÓN

Contenidos

- I. Introducción
- II. Definiciones
- III. Extracción de reglas de asociación
- IV. Apriori
- V. Reglas de asociación en Orange
- VI. Actividad

Introducción

PROBLEMA

Dado un conjunto de eventos (objetos), encontrar reglas que describan relaciones causa-efecto entre ellos

Ejemplo: la cesta de la compra




Detectar cuándo la ocurrencia de un artículo esta asociada a la ocurrencia de otros artículos en la misma compra

Introducción

ANÁLISIS DE LA CESTA DE LA COMPRA

Origen de las reglas de asociación



Aplicaciones:

Diseño de catálogos, distribución de los productos en los supermercados, . . .

Introducción

Colocación de productos en las estanterías de un supermercado

- **Objetivo:** Identificar productos que muchos clientes compran juntos.
- **Solución:** Procesar los datos de los terminales de punto de venta proporcionados por los escáneres de código de barras.
- **Ejemplo:** Si un cliente hombre compra pañales, es muy probable que compre cerveza



Introducción

Promociones y ofertas


Si identificamos una regla del tipo: **{café} → {leche}**

- Aquellos clientes que compran café, tienen tendencia a comprar leche.
- No ocurre lo mismo a la inversa: los que compran leche no muestran una tendencia especial a comprar café.

Introducción

En la terminología del “análisis de la cesta de la compra” los datos consisten en:

- Una serie de registros de transacciones
- Cada registro contiene un conjunto de artículos comprados por un cliente




Los datos se pueden visualizar como una matriz:

Cliente	Pan	Leche	Vino	Huevos	Pañales	Cerveza
1	1	1	1	1	0	0
2	1	0	1	0	1	1
3	0	1	1	0	1	1


Aplicaciones Reales

Aplicaciones

Microarray de Spellman y ciclo celular de la levadura




Microarray de inflamación y respuesta inmune



Enfermedad Alzheimer

Predicciones agronómicas

Series temporales multidimensionales



Datos sísmicos temporales

Contenido total de ozono en la atmósfera mediante mediciones por satélite



Series temporales del mundo real: Contaminación atmosférica
 O_3 , NO , SO_2

Aplicaciones Reales. Contaminación Atmosférica

Reglas de asociación encontradas por QARGA para condiciones climatológicas con respecto a O₃ (mg / m³) y SO₂(mg / m³)

Rule	Conf. (%)	Lift
Temp. E [38, 42] and Hum. E [25, 33] and Hour E [15, 18] \Rightarrow O ₃ E [140, 206]	90	6.61
Temp. E [16, 22] and Hum. E [75, 90] \Rightarrow O ₃ E [22, 110]	100	1.43
Temp. E [42.9, 45.0] \Rightarrow SO ₂ E [3.7, 7.5]	100	1.72

Reglas de asociación encontradas por Apriori

Rule (%)	Conf.	Lift	#intervals discretization
Temp. E [24, 27] \Rightarrow O ₃ E [90, 115]	33	1.43	10
Hum. E [14, 40] and Dir. E [120, 240] \Rightarrow O ₃ E [99, 183]	73	1.80	3

* Todas las variables fueron proporcionadas por la estación meteorológica de la ciudad de Sevilla (Spain)

M. Martínez Ballesteros, F.Martínez-Álvarez, A. Troncoso Lora, J.C. Riquelme Santos. "An Evolutionary Algorithm to Discover Quantitative Association Rules in Multidimensional Time Series". Soft Computing. Vol. 15, No. 10, pp. 2065-2084. 2011. ISSN: 1432-7643. DOI:10.1007/S00500-011-0705-4.

Definiciones

■ Itemset:

- Conjunto de uno o más items, p.ej. {pan, leche}
- K-itemset. Itemset con k elementos

■ Soporte de un itemset (support):

- Frecuencia relativa de aparición del itemset en cuestión dentro de todos los itemsets del conjunto de datos

p.ej. sup({pañales, cerveza}) = 2/3

■ Itemset frecuente:

- Itemset con soporte igual o superior a un umbral de soporte establecido por el usuario (MinSup).

Itemsets del conjunto de datos:

Cliente	Compras
1	Pan, leche, vino, huevos
2	Pan, pañales, cerveza
3	Leche, pañales, vino, cerveza


Definiciones

Descubrimiento de Reglas de Asociación:

Aprendizaje no supervisado para descubrir relaciones entre atributos



Una regla de asociación es una **implicación** de la forma:



Antecedente Consecuente

A y C están formados por itemsets

Definiciones

■ Reglas de asociación Booleanas:

- Asociaciones entre la presencia y ausencia de items. *E.g. compra A o no compra A.*

Leche y Huevos \Rightarrow Pan

■ Reglas de asociación nominales:

- Asociaciones entre las propiedades o valores de items (discretos).

Temperatura es FRÍA y Humedad es NORMAL \Rightarrow Jugar es SI

■ Reglas de asociación cuantitativas:

- Asociaciones entre items o atributos cuantitativos (continuos).

Temperatura E [38, 42] y Humedad E [25, 33] \Rightarrow Ozono Troposférico E [140,206]

Definiciones

■ Regla de Asociación

- Implicación de la forma $A \rightarrow C$, donde A e C son itemsets
- **Ejemplo:** {Leche, Huevos} \rightarrow {Pan}

■ Métricas de evaluación

- **Soporte:** Fracción de ejemplos que contienen tanto A como C:

$$Sup(A \rightarrow C) = P(A \wedge C) = \frac{\#(A \wedge C)}{N}$$

- **Confianza:** Frecuencia de casos en los que aparece A y C con respecto al total de casos que incluyen A:

$$Conf(A \rightarrow C) = P(A | C) = \frac{Sup(A \rightarrow C)}{Sup(A)}$$

- **Lift:** Indica cuándo una regla es mejor prediciendo el resultado que asumiendo el resultado de forma aleatoria. Si el resultado es mayor que uno, la regla es significativa:

$$Lift(A \rightarrow C) = \frac{Conf(A \rightarrow C)}{Sup(C)}$$

Cliente	Compras
1	Pan, leche, vino, huevos
2	Pan, pañales, cerveza
3	Leche, pañales, vino, cerveza
4	Pan, leche, pañales, cerveza
5	Pan, leche, pañales

Ejemplo: {cerveza} \rightarrow {pañales}

$$Sup(\{\text{cerveza}\}) = 3/5$$

$$Sup(\{\text{pañales}\}) = 4/5$$


$$Sup(\{\text{cerveza}\} \rightarrow \{\text{pañales}\}) = Sup(\{\text{cerveza, pañales}\}) = 3/5$$

$$\begin{aligned} Conf(\{\text{cerveza}\} \rightarrow \{\text{pañales}\}) &= Sup(\{\text{cerveza, pañales}\}) / Sup(\{\text{cerveza}\}) \\ &= (3/5) / (3/5) = 1 \end{aligned}$$

$$\begin{aligned} Lift(\{\text{cerveza}\} \rightarrow \{\text{pañales}\}) &= Conf(\{\text{cerveza}\} \rightarrow \{\text{pañales}\}) / Sup(\{\text{pañales}\}) \\ &= 1 / (4/5) = 5/4 = 1.25 \end{aligned}$$

Reglas de asociación en Orange

- El add-on “Associate” contiene los métodos orientados a buscar asociaciones entre datos.
- Es importante reseñar que estos métodos solo funcionan con datos cualitativos.
- Es un add-on sencillo y simple de usar, con pocas opciones, basta con seleccionar un método, configurarlo y probarlo.



Reglas de asociación en Orange

FPGrowth → Usado por Orange


- Presenta un buen rendimiento utilizando la estructura FP-Tree (árbol de patrones frecuentes).
- Haciendo uso de dicha estructura de almacenamiento se reduce el coste de computación del proceso de obtención de reglas de asociación.
- No es necesario generar los conjuntos de ítems candidatos a frecuentes y tampoco comprobar si superan un determinado umbral.
- Reduce iterativamente el soporte mínimo hasta que encuentra el número de reglas requerido con un valor mínimo para la métrica indicada.



Reglas de asociación en Orange

Nodo Association Rules


- Find association rules: se puede indicar el criterio a seguir para inducir las reglas:
 - Soporte mínimo
 - Confianza mínima
 - Máx número de reglas
- Filter rules: las reglas generadas se pueden filtrar por varios criterios. Por ejemplo, el antecedente o el consecuente



Reglas de asociación en Orange

Nodo Frequent Itemsets

- Este widget encuentra itemsets frecuentes según unos parámetros a elegir:
 - Soporte mínimo
 - Máximo número de itemsets
 - Filtro



Actividad – Reglas asociativas en salarios

- Utilizaremos el conjunto de datos **Adult** que viene integrado en Orange

Actividad – Reglas asociativas en salarios

- Véamos con el nodo **Frequent Itemsets** cuáles son las reglas más comunes:

1. Si pulsamos sobre Collapse All, sólo se mostrarán los atributos/valores “TOP”.
2. Si se expande cada uno de los ítems, se pueden observar cuáles son los atributos/valores conectados a él.
3. Intente extraer alguna regla de asociación a partir del primer ítem.

- Para poder extraer las reglas de asociación usaremos el nodo **Association Rules**

- Observemos la medida **lift**: Si el valor de lift es 1, entonces el antecedente y el consecuente son independientes. Cuanto más alto sea este valor, mayor será la probabilidad de que la existencia del antecedente y el consecuente juntos en una instancia no es sólo una ocurrencia aleatoria, sino debido a una cierta relación entre ellos.



The screenshot shows the KNIME interface with the 'Association Rules' node open. On the left, the configuration panel displays settings for finding rules: Min.supp.: 20 %, Min.conf.: 1 %, Max.rules: 10k, Induce only classification rules checked, and Restrict search by below filters checked. Below these are two filter sections: 'Filter by Antecedent' and 'Filter by Consequent', each with a 'Contains:' field and an 'Items,min: 1 max: 999' dropdown. At the bottom of the configuration panel are 'Send selection' and 'Send all' buttons. To the right, the results table is titled 'Association Rules' and lists 15 rules. The columns are labeled: Supp, Conf, Covr, Strg, Lift, Levr, Antecedent, and Consequent. The first few rows of the table are as follows:

Supp	Conf	Covr	Strg	Lift	Levr	Antecedent	Consequent
0.206	0.447	0.460	0.524	1.856	0.095	marital-status=Married-civ-spouse	$\rightarrow y \geq 50K$
0.206	0.975	0.211	3.598	1.284	0.045	marital-status=Never-married,workclass=Private,age <= 35.25	$\rightarrow y \leq 50K$
0.262	0.974	0.269	2.826	1.283	0.058	marital-status=Never-married,age <= 35.25	$\rightarrow y \leq 50K$
0.241	0.960	0.251	3.020	1.264	0.050	marital-status=Never-married,workclass=Private	$\rightarrow y \leq 50K$
0.313	0.954	0.328	2.314	1.257	0.064		marital-status=Never-married
0.229	0.897	0.255	2.977	1.181	0.035		relationship=Not-in-family
0.317	0.892	0.356	2.134	1.175	0.047	workclass=Private,age <= 35.25	$\rightarrow y \leq 50K$
0.406	0.886	0.458	1.656	1.167	0.058		age <= 35.25
0.205	0.856	0.239	3.177	1.128	0.023	education=HS-grad,workclass=Private	$\rightarrow y \leq 50K$
0.271	0.840	0.323	2.354	1.107	0.026		education=HS-grad
0.545	0.781	0.697	1.089	1.029	0.015		workclass=Private
0.247	0.633	0.390	1.944	0.834	-0.049		age = 35.25 - 53.5
0.254	0.553	0.460	1.651	0.729	-0.095		marital-status=Married-civ-spouse
0.223	0.551	0.405	1.874	0.726	-0.084		relationship=Husband
0.223	0.551	0.405	1.875	0.726	-0.084		relationship=Husband,marital-status=Married-civ-spouse